

神经网络导论

戴 葵

国防科技大学计算机学院601教研室



神经网络研究背景



- ☾★ 人类的智能
- ☾★ 传统智能信息处理技术面临的问题
- ☾★ 神经网络学科的产生
- ☾★ 神经网络研究的历史
- ☾★ 神经网络研究的意义

神经网络的研究内容



- ☾ 神经网络基础理论
- ☾ 神经网络实现技术
- ☾ 神经网络应用技术

本课程的学习计划

★ 课时分配

★ 课程要求


注重基本理论

注重应用

注重理论、应用和实践相结合

★ 考试

课程设计+报告+笔试



第一章

神经网络基本概念



内容提要



- ✻ 神经网络模型的基本组成
- ✻ 神经网络的分类及典型的神经网络模型
- ✻ 神经网络结构及神经计算特点
- ✻ 神经计算的稳定性
- ✻ 神经网络研究历史
- ✻ 神经网络的应用领域

第一节



神经网络模型的基本组成

神经网络模型的基本组成 之神经元

生物神经元的基本组成

细胞体

突起

✧ 树突

✧ 轴突


人工神经元的基本结构

处理单元

连接

✧ 输入

✧ 输出



神经元的基本功能（1）

☀ 接收输入

☼ 输入类型


☼ 输入的权值

☼ 抑制性连接权值

☼ 活跃性连接权值

☼ 传播规则（传播函数）

把某类净输入与其连接权值结合起来，使该类输入对目的处理单元产生最终净输入的规则。



神经元的基本功能 (2)


✴ 处理输入

- ✴ 活跃状态（活跃值）
- ✴ 活跃值
- ✴ 活跃函数（活跃规则）

把某一处理单元的各类净输入相互结合起来，再与该处理单元当前活跃状态相结合，以产生一个新的活跃状态的规则。

✴ 活跃函数类型

恒等函数、阈值函数、S型单调函数



神经元的基本功能（3）

✴ 产生输出


✴ 输出值的作用

✴ 输出函数（输出规则）


根据某一神经元的当前活跃值产生对其它神经元影响的输出值的规则。

✴ 输出函数类型

硬极限函数、阈值函数、S型单调函数、恒等函数



$$o_i(t+1) = f_i(a_i(t+1))$$



神经网络模型的基本组成 之网络

神经网络结构



连接矩阵

连接模式

多层、单层

反馈、前馈

$$W = \begin{bmatrix} w_{11} & \cdots & w_{1n} \\ \vdots & \ddots & \vdots \\ w_{n1} & \cdots & w_{nn} \end{bmatrix}$$



神经网络模型的基本组成 之学习规则

学习规则

根据环境动态修改各个处理单元之间连接权值的规则。

典型的学习规则

☀ Hebbian学习规则

☀ Delta学习规则


学习的类型

☀ 联想学习

☀ 自联想

☀ 异联想

☀ 规则发现



神经网络模型的基本组成 之环境

☀ 环境内容

☀ 输入

☀ 输出




神经网络模型的基本组成

小结

- ✻ 传播规则
- ✻ 活跃规则
- ✻ 输出规则
- ✻ 互连模式
- ✻ 学习规则
- ✻ 环境

神经网络模型完整描述的六个要素。

第二节



神经网络的分类以及 典型的神经网络模型

神经网络分类原则

- ✿按神经网络模型的拓扑结构可以分为反馈神经网络模型和前向神经网络模型。
- ✿按神经网络模型的性能可分为连续型与离散型神经网络模型，确定型与随机型神经网络模型。
- ✿按学习方式可以分为有教师学习神经网络模型和无教师学习神经网络模型。
- ✿按连接突触性质可以分为一阶线性关联神经网络模型和高阶非线性关联神经网络模型。

典型的神经网络模型

✿ 自适应谐振理论（ART）

该模型主要包括ART1、ART2和ART3，它们可以对任意多和任意复杂的二维模式进行自组织、自稳定和大规模并行处理。ART1主要用于二值输入，ART2和ART3主要用于连续信号输入。该类模型主要用于模式识别（如雷达、声纳的信号识别）。

缺点是对转换、失真及规模的变化较为敏感。

典型的神经网络模型

❁ 雪崩模型（Avalanche）

该类神经网络模型可以学习、记忆和重现随机复杂度的时空模式。主要用于连续的语音识别和教学机器人。

缺点是调节困难。

典型的神经网络模型

❁ 双向相联存储器（BAM）

该类神经网络模型是由许多相同神经元构成的双向联想式两层网络，主要用作按内容寻址的相联存储。

缺点是存储容量小而且需很好地进行编码。

典型的神经网络模型

❁ 反传神经网络模型 (BP)

该类神经网络模型是一多层映射神经网络。采用的是最小均方差的学习方式，是目前使用最广泛的神经网络模型之一。主要用于语言综合、语言识别、自适应控制等。

缺点是它仅仅是有监督的一种学习方式，而且输入、输出样本都必须是冗余的。

典型的神经网络模型

✿ Boltzmann机 / Cauchy机 (BCM)

该类神经网络模型使用一噪声过程求得整个模型花费函数（cost function）的全局极小值。主要用于模式识别（图像、声纳和雷达信号的识别）。

缺点是Boltzmann机的训练时间长，Cauchy机会按一定的统计分布产生噪声。

典型的神经网络模型

❁ 盒中脑状态模型 (BSB)

该类神经网络模型是具有最小均方差的单层自联想网络模型。可以用于从数据库中提取知识。

缺点是仅仅为单步决策，没有交互性的推理。

典型的神经网络模型

❁ 对流传播模型（CPN）

该类神经网络模型是一种在功能上作为统计最优化和概率密度函数分析的网络模型。主要用于图像压缩、统计分析、贷款应用打分。

缺点是对任何类型的问题均需大量的处理单元和连接。

典型的神经网络模型

✿ Hopfield神经网络模型

它是由相同处理单元构成的单层自联想网络模型。主要用于从片段中进行图像和数据的完全恢复。

缺点是处理单元间连接权值需预先设置，并且单元之间的连接是要对称的，它没有学习能力。

典型的神经网络模型

✿ 多个自适应线性元模型（MADALINE）

该类神经网络模型是具有最小方差学习功能的线性网络模型。它的学习能力较强，是自适应线性元ADALINE的扩展。主要用于自适应控制。

缺点是在输入输出之间设置的是一种线性关系。

典型的神经网络模型

❁ 自组织映射模型（SOM）

该类神经网络模型主要是形成从一个密集簇到另一个簇的连续拓扑映射，并且映射矩阵密度随第二个簇所给定的概率密度函数不同而不同。主要用于从一个几何区域到另一个几何区域的映射。

缺点是需要彻底的训练。

典型的神经网络模型

❁ 学习矩阵模型 (LRN)

该类神经网络模型是一种单层单向非递归的相联存储器模型。主要用于相联存储。

典型的神经网络模型

❁ 小脑模型（Cerebellatron）

该类神经网络模型主要是学习平均时空指令序列模式，并且按线索重现那些平均指令序列。主要用于控制机械手的动作。

缺点是需要复杂的控制输入。

典型的神经网络模型

❁ 细胞神经网络模型（CNN）

该类神经网络模型是一单层连续神经网络。主要用于模式识别、文字识别与噪声控制等。

典型的神经网络模型

✿ 交替投影神经网络模型 (APNN)

该类神经网络模型应用凸集投影概念，在向量空间中建立模型，主要用于模式识别。

典型的神经网络模型

❁ 神经认知机 (Necognitron)

该类神经网络模型是一多层结构化字符识别网络模型。主要用于手写体字符识别，但是常常需要极大数目的处理单元和连接，它对大小、平移、旋转不敏感，并且能识别复杂的字符。

典型的神经网络模型

✿ 感知机 (Perceptron)

该类神经网络模型是一组可训练的线性分类单层网络模型，目前较少应用。主要用于打印字符识别，但是不能识别复杂字符（汉字），而且对大小、平移和变形很敏感。

典型的神经网络模型的分类

❁ 前馈神经网络模型

- ❁ 自适应线性元模型

- ❁ 感知机

典型的神经网络模型的分类

❁ 反馈神经网络模型

- ❁ Hopfield神经网络模型
- ❁ 海明神经网络模型
- ❁ 双向联想存储器

典型的神经网络模型的分类

❁ 自组织神经网络模型

- ❁ 自适应谐振理论（ART）
- ❁ 自组织映射神经网络模型（SOM）
- ❁ 对流神经网络模型（CPN）
- ❁ 认知机

典型的神经网络模型的分类

❁ 随机神经网络模型

- ❁ 模拟退火算法
- ❁ Boltzmann机
- ❁ 谐和理论

第三节

A thick, horizontal yellow brushstroke with a textured, painterly appearance, spanning the width of the slide below the section header.

神经网络结构及 神经计算特点

神经网络模型结构特点

✿ 神经网络模型是由大量极简单的处理单元所组成

每一个处理单元仅仅是对输入信号加权求和，然后计算该处理单元新的活跃值和输出信号。每个处理单元要完成的功能非常简单，但是神经网络模型中的处理单元数目是如此之多，传统计算机是远远无法比拟的。

神经网络模型结构特点

✿ 高度复杂的互连

在神经网络模型中处理单元与处理单元之间存在着高度复杂的互连，有的是在每一个处理单元之间都存在着互连；有的是在层与层之间的处理单元间存在互连，这主要取决于实际问题和所要达到的性能要求。而在传统计算机中，对于单机系统来说不存在互连问题，在双机或多机系统中，处理机之间的互连数也是有限的。

神经计算的本质

✿ 计算的数学观点

计算就是在满足一定原理、定理的条件下，从一个空间到另一个空间的映射；

✿ 计算的物理观点

计算是按照一定的自然规则，在某种“硬件”上所发生的一些物理规则。因此计算可以表示为一动力学系统中状态空间的变换轨迹。

神经计算的本质



神经网络的计算是一种非编程的信息处理方式。在不确定的条件下，只要我们能准确地描述所要求的计算功能，并能给出体现该功能的大量例子，那么神经网络就可以通过这些例子来进行自我调整，直至达到所要求的计算能力；有时甚至在没有例子可寻时，神经网络也可以根据一些输入信号通过自组织而达到某种计算能力。

神经计算的本质



上述这种非编程的自适应信息处理方式称之为神经计算（neurocomputing）。

如果把神经网络看成是由大量子系统组成的大系统，那么神经计算就是该系统状态的转换，其计算过程可以认为是状态的转换过程。

神经计算的特点

- ❁ 大规模并行性、集团运算和容错能力。
- ❁ 信息的分布式表示。
- ❁ 学习和自组织能力。
- ❁ 多层神经网络系统具有强大的解算能力和处理实际问题的能力。

神经计算的信息处理能力

✿ 数学逼近映射

$$f: A \subset R^n \rightarrow B \subset R^n$$

开发合适的函数，以自组织的方式响应以下的样本集合： $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$ ，
（这里 $y_i = f(x_i)$ 或 $y_i = f(x_i) + N$ ，其中 N 为噪音过程）。这里描述的当然是一般的数学抽象，像识别与分类这些计算都可以抽象为这样的一种近似数学映射。BPN、CPN模型都可以完成这种计算。

神经计算的信息处理能力

✿ 概率密度函数的估计

通过自组织的方式开发出一组等概率锚点来响应在空间中按照一定确定概率密度函数 p 选取的一组向量样本 X_1, X_2, X_3, \dots 。CPN、SOM模型可以完成这种计算。

神经计算的信息处理能力

✿ 从二进制数据基中提取相关的知识

将从二进制数据基中提取的相关知识形成一种知识的聚集模型，这些知识依照数据基的自组织在它们之间有某种统计上的共性，并依这些共性来响应输入的数据基。BSB有能力进行这种计算。

神经计算的信息处理能力

❁ 形成拓扑连续及统计意义上的同构映射

这是对固定概率密度函数选择的输入数据进行自适应的一种自组织映射，最终使得数据空间上的不同项有某种同构。SOM 模型最适合计算这类问题。

神经计算的信息处理能力

✿ 最近相邻模式分类

通过比较大量的存储数据来进行模式分类，这种能力可应用于暂态或暂稳态模式分类，并且可用层次性的存储模式来表达存储。绝大多数的神经网络模型均能进行这种计算，比如ART、AVA、BAM、BCM、BPN、BSB、CBD、CPN、HOP、LRN、MDL、NEO、PTR。

神经计算的信息处理能力

❁ 数据聚集

这是采用自组织的方式所选择的颗粒或模式的聚类，以此来响应输入数据。聚类是可变的，但要限制其鞍点的个数。对于任何新的目标，只要在系统中没有对其提供聚类，都要形成新的聚类。很显然，这种能力可直接应用于雷达的多目标跟踪，ART模型最适于这种计算。

神经计算的信息处理能力

✿ 最优化问题的计算

这是用来求解局部甚至是全局最优解的，
HOP模型、BCM 模型有能力进行这种计算。

第四节



神经计算的稳定性

稳定性的基本概念


稳定性是指神经网络系统在进行神经计算时，系统最终能收敛到一个稳定状态。只有使整个神经网络系统的状态朝稳定状态发展的神经计算才是有用的，否则，将导致整个系统的振荡或者随机波动，而不能得到一个一致的结果。

从计算机的角度看稳定性



计算机具有许多可能的逻辑状态。当计算机系统时钟不断推进时，计算机就从一个逻辑状态转换到另一个逻辑状态。在计算机中，通过设置特定的逻辑初始状态开始计算（指令和数据）。然后计算机的状态就沿着事先确定的逻辑状态空间上的轨迹移动，直到得到答案，整个计算也就结束了。因而在计算机中的计算过程就是其逻辑状态空间中的一条轨迹。


从物理的角度看稳定性




从物理的角度来看，计算过程是其相应状态空间上状态变换的一条轨迹，这条轨迹的方向由该系统固有动力学特性控制着，其移动的结果是进入一稳定状态中，然后整个计算便结束了。

由该系统固有动力学特性控制着的各种物理系统可以展示不同的计算能力，

离散状态空间下的计算过程解释



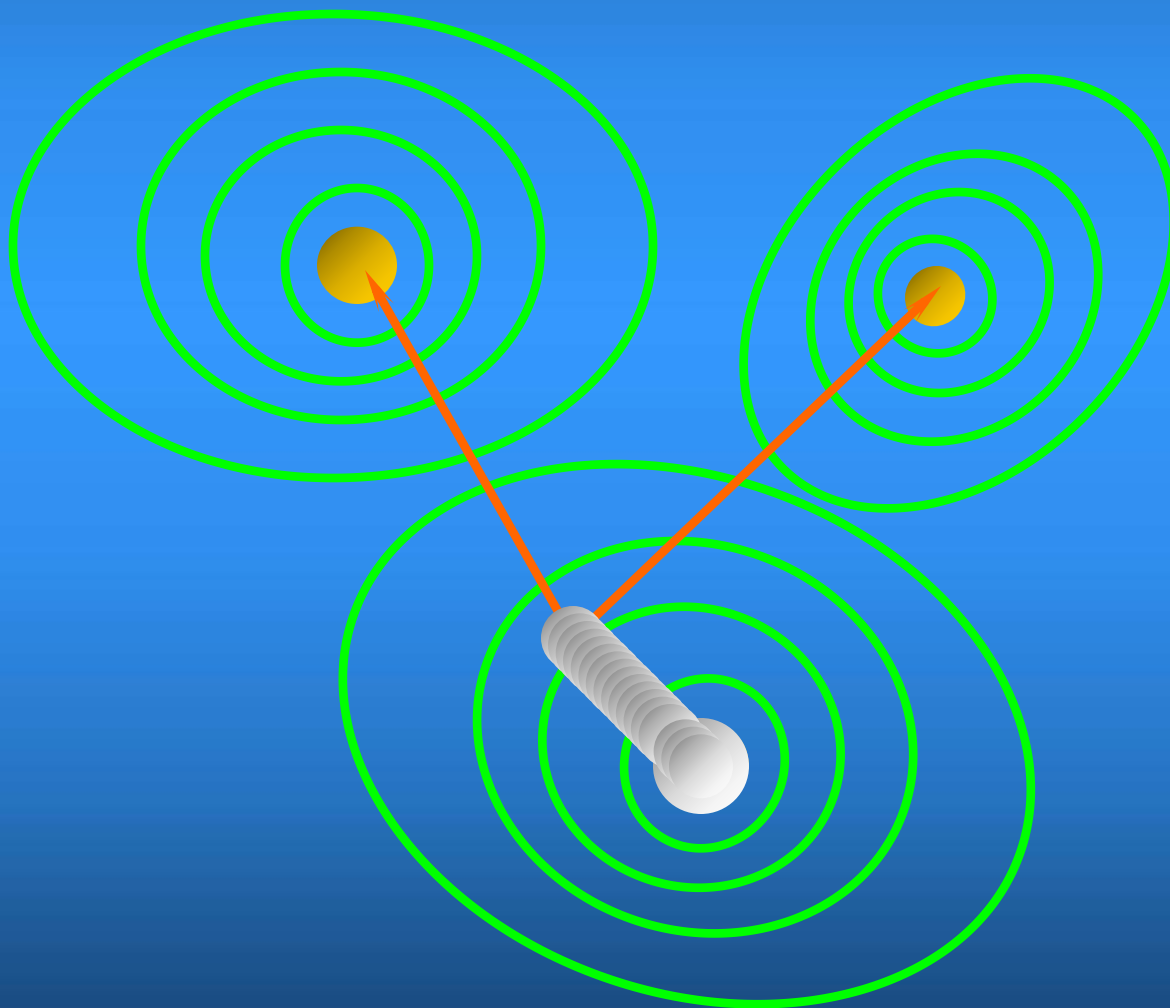
连续状态空间下计算过程的解释



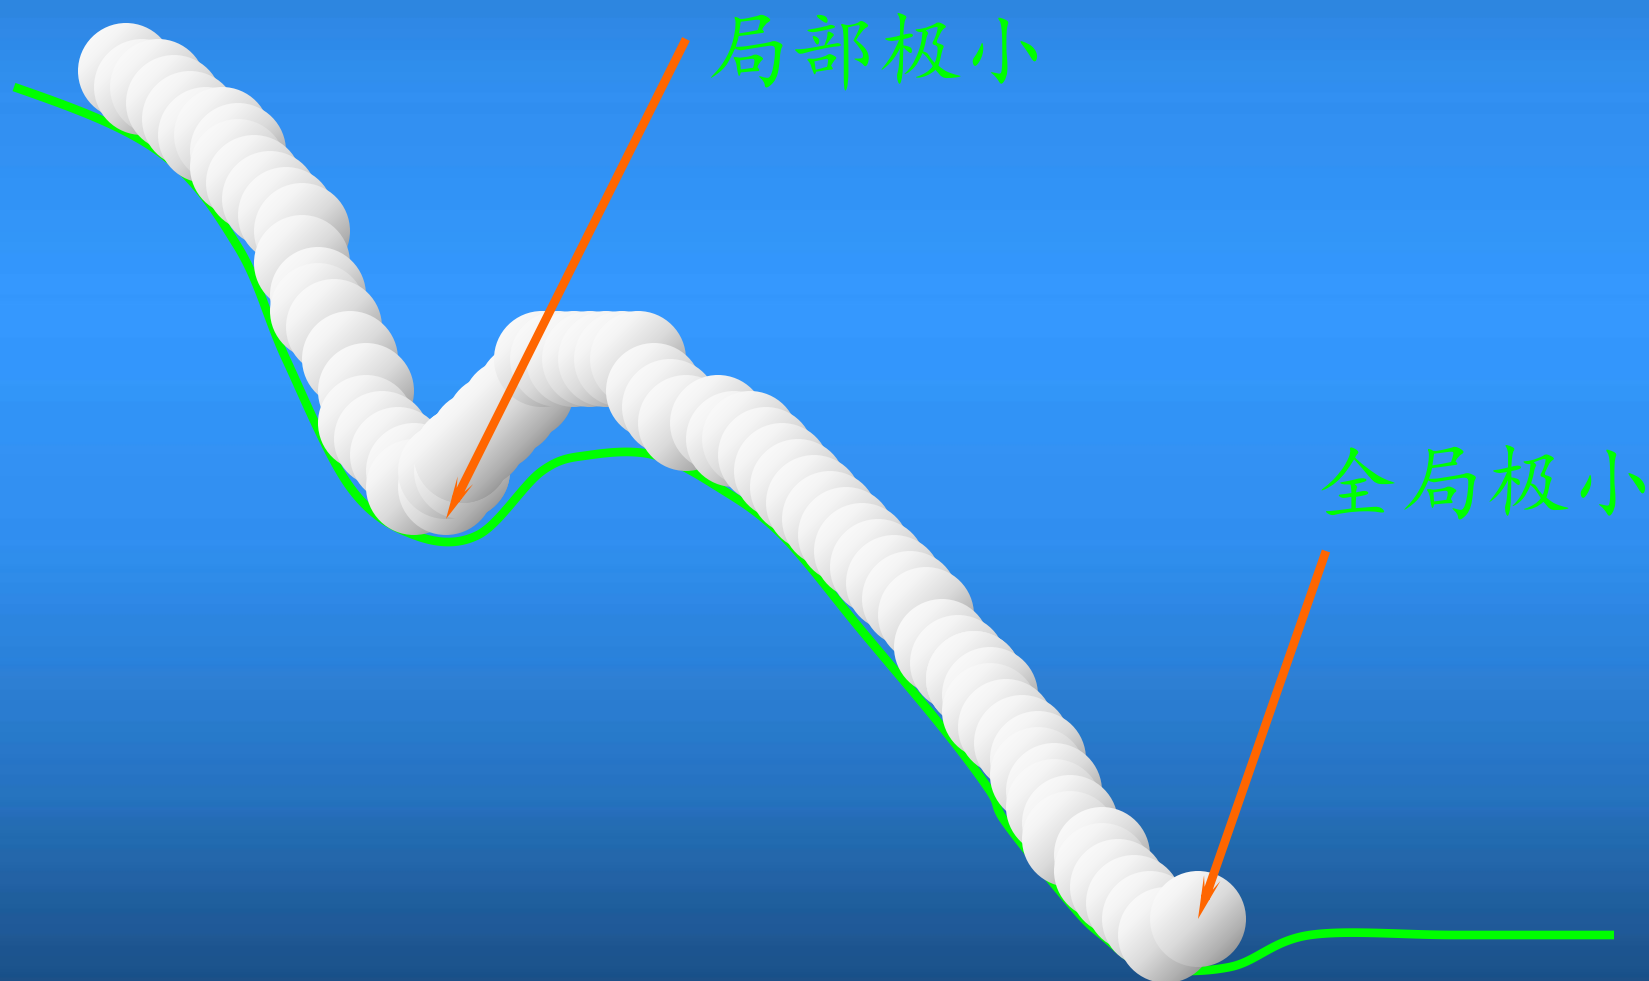
神经计算过程的数学描述

假定状态空间向量为 $X=(x_1, x_2, \dots, x_n)^T$ ，系统的局部稳定点为 x_a, x_b, \dots 。只要系统初始点充分地靠近 $x_i \in \{x_a, x_b, \dots\}$ ，比如 $x_{in} = x_i + \Delta$ （ x_{in} 为系统初始点），则系统必随时间的演变而达到稳定点 x_i 。这种稳定点也叫系统的吸引子或极小点。这里的 $x_i + \Delta$ 代表了 x_i 的部分知识，可以从系统中查询到其完整的知识，也就是说系统具有相联搜索的能力。

吸引子的物理含义图解1



吸引子的物理含义图解2



第五节



神经网络的研究历史

神经网络研究简史



从人脑的生理结构出发来研究人的智能行为，模拟人脑信息处理的功能，即人工神经网络的研究，始于本世纪四十年代，但它的发展却经历了一条曲折的道路，至今经历了兴起、萧条和兴盛三个时期。

第六节



神经网络的应用领域

神经网络潜在应用领域

- ❁ 传感器信息处理
- ❁ 信号处理
- ❁ 自动控制
- ❁ 知识处理
- ❁ 市场分析
- ❁ 运输与通信
- ❁ 神经科学和生物学

神经网络潜在应用领域

- ❁ 娱乐。比如下棋、打牌等。
- ❁ 零售分析。用神经网络来分析各种商品的零售量及价格。
- ❁ 信用分析。
- ❁ 航空与航天。
- ❁ 医用诊断系统。

第五章

随机神经网络模型

内容提要

& 模拟退火算法

& Boltzmann机

第一节

模拟退火算法


神经计算中面临的问题

利用神经网络进行计算时，我们总是期望能通过系统状态的改变，使系统的能量函数 E 朝其减小的方向递减，然而这个递减过程最终所达到的一个稳定状态，往往是能量函数 E 的一个局部极小点，而达不到全局最优。如果利用神经网络计算求解具有多个限制条件的组合优化问题时，这个局部极小点所能满足的只是其中一些限制条件，只是达到了局部最优而不是全局最优，这当然不是我们所期望的结果，但是我们又怎样才能寻求到满足多数限制条件的全局最优点（或次优点）呢？

物理中的退火过程

在物理学中，对固体物质进行退火处理时，通常先将它加温溶化，使其中的粒子可自由地运动，然后随着物质温度的下降，粒子也形成了低能态的晶格。若在凝结点附近的温度下降速度足够慢，则固体物质一定会形成最低能量的基态。对于组合优化问题来说，它也有类似的过程，也就是说物理中固体物质的退火过程与组合优化问题具有相似性。组合优化问题也是在解空间寻求花费函数最小（或最大）的解。

模拟退火算法的直观解释



模拟退火算法基本思想

在神经网络系统中，设系统所有可能状态为 $V = \{v_1, v_2, \dots, v_n\}$ ，与系统相对应有一能量 E ，它是系统状态的函数，即 $E(V)$ 。设控制参数为温度 T ，我们的目的便是找到某一系统状态 V^* ，使：

$$E(V^*) = \min_{v_i \in V} (v_i)$$

模拟退火算法的基本思想

◆ 模拟退火思想是：

让 T 从一个足够高的值慢慢下降，对每个 T ，用Metropolis抽样法在计算机上模拟该系统在此 T 下的热平衡状态，即对当前状态 V_i 经过随机扰动产生一个新状态 V_j ，计算系统的能量增量： $\Delta E = E(V_j) - E(V_i)$ ，并以概率接受 V_j 作为新的当前状态。当重复地如此随机扰动数次后，状态 V_i 又重新作为当前状态的概率将服从Boltzmann分布。

模拟退火算法的基本思想

$$f = z(T)e^{-\frac{E(v_i)}{kT}}$$

其中：

$$z(T) = \frac{1}{\sum_i e^{-\frac{E(v_i)}{kT}}}$$

k为Boltzmann常数。

模拟退火算法基本思想

若 T 下降足够慢, 且 $T \rightarrow 0$, 从上式可知, 系统所处的当前状态 V_i 将具有最小的能量值 $E(V_i)$ 。

模拟退火算法描述

- 1、初始化。任给一初始状态 V_0 ， $V_i=V_0$ ，计算 $E(V_0)$ ，将参数 T 置一初始温度值。
- 2、产生一随机扰动 ΔV ，按下式计算 ΔE ：

$$\Delta E = E(V_i + \Delta V) - E(V_i)$$

- 3、若 $\Delta E < 0$ ，则转5，否则在 $(0, 1)$ 区间上产生一个均匀分布的随机数 ξ 。

模拟退火算法描述

- 4、若 $e^{-\Delta E/kT} \leq \xi$, 则转2。
- 5、用 $V_i + \Delta V$ 来取代原来的 V_i , 并令 $E = E + \Delta E$ 。
- 6、在该 T 下, 检验系统是否稳定, 若不稳定则转2。
- 7、以某一方式取 $T^* < T$, 令 $T = T^*$ 。
- 8、退火过程是否基本结束, 是就停止, 不是则转2。

对模拟退火算法的一些说明

在上述过程中，模拟退火是否能达到能量 E 的最小值，取决于 T_0 是否足够高和 T 下降得是否充分慢，以及对每个 T 时系统是否稳定。

对模拟退火算法的一些说明

◆ T_0 初始选取

- 1、均匀地随机抽样 V ，取 $E(V)$ 的方差为 T_0 。
- 2、在所有可能状态下，选取两个状态 V_i 和 V_j ，使差 $|\Delta E| = |E(V_i) - E(V_j)|$ 最大，取 T_0 为该量大值的若干倍。
- 3、由经验给出。

对模拟退火算法的一些说明

◆ 检验系统是否稳定的方法

- 1、检查E的均值是否稳定。
- 2、检查是否连续若干步中E的变化都比较小。
- 3、按一固定步数抽样。

对模拟退火算法的一些说明

◆ T减小方式

令 $T = \lambda T$, $0 < \lambda < 1$, 常数 $\lambda \in [0.8, 0.99]$ 。

◆ 算法终止方式

- 1、取 t 小于某一阈值。
- 2、检验系统的熵是否已达最小。


第二节

Boltzmann机

Boltzmann机简介

Boltzmann机是由Hinton和Sejnowski提出的一种统计神经网络模型，是在Hopfield网络基础之上引入了随机性机制而形成的。与Hopfield神经网络不同的是Boltzmann机具有学习能力，即其权值通过学习来调整，而不是预先设置。Boltzmann机是一种约束满足神经网络模型。

Boltzmann机的结构



Boltzmann机的学习

当样本送入Boltzmann机的可见单元后，Boltzmann机就开始学习。Boltzmann机中的隐含单元是用来形成内部表示，以描述输入样本的规律。由于内部表达的构造过程是在无任何附加信息的状态下完成的，因而这个学习过程也称为无监督学习。设所有的权值初始值都为0。

Boltzmann机的学习过程描述

◆ 输入期

学习样本送入Boltzmann机的可见神经元，并且对每一个输入样本使用当前权值建立平衡。也就是说，从训练集合中随机挑选一样本送入可见神经元，然后让隐含神经元自由动作，这时，如果两个神经元的状态同时为1，统计它们之间连接的权值活跃的次數 L_1 。

Boltzmann机的学习过程描述

◆自由运行期

这时Boltzmann机中所有的神经元都自由地调整它们的状态，采用模拟退火算法达到一个平衡态，统计神经元之间连接权值活跃的次数 L_2 。

Boltzmann机的学习过程描述

◆ 调整连接权值

按下式进行连接权值调整：

$$\Delta w_{ij} = \eta(L_2 - L_1)$$

Boltzmann机的应用

◆ 数字编码问题

